UNIVERSIDAD DE LAS AMÉRICAS

S1-TEMA INICIAL Y PLAN METODOLOGICO

PROYECTO MIA

TTMZ0055-462

GRUPO 5

Integrantes:

- Peter Cañizares
- Henry Mantilla

25/10/2026

Índice

Resumen ejecutivo 3
1. Antecedentes y actualización de la propuesta 3
2. Definición del problema 3
2.1 Pregunta de investigación 4
2.2 Delimitación y alcance 4
2.3 Factibilidad del caso 4
3. Justificación 5
4. Objetivos 5
4.1 Objetivo general 5
4.2 Objetivos específicos e indicadores 5
5. Alternativas de solución y selección preliminar 6
6. Plan metodológico 6
6.1 Fases, técnicas y productos 6
6.2 Procedimiento de datos y selección de modelo 7
6.3 Indicadores y evaluación 7
6.4 Controles de calidad, ética y riesgos 8
7. Cronograma tentativo y entregables 8
7.1 Responsabilidades y seguimiento 9
8. Riesgos y contingencias 9
9. Aportes y resultados esperados 9
10. Referencias bibliográficas 10
Anexo A. Trazabilidad de observaciones del Comité 10
Anexo B. Verificación frente a rúbrica S1 11
Anexo C. Información pendiente de verificación 11

TEMA INICIAL Y PLAN METODOLÓGICO

“Plataforma inteligente multisectorial para generación, segmentación y recomendación de campañas de marketing digital mediante IA generativa y aprendizaje automático”.

Integrantes: Peter Cañizares Cárdenas y Henry Mantilla Avilés
Curso: TTMZ0055-462 – Proyecto MIA
Versión actualizada con observaciones del Comité de Titulación
Fecha: 25 de octubre de 2026 · Horizonte de planificación: octubre de 2026 a marzo de 2027

Resumen ejecutivo

Se propone diseñar, implementar y evaluar un prototipo funcional (MVP) de una plataforma configurable para apoyar la preparación de campañas digitales en pequeñas empresas de distintos sectores. El sistema combinará generación de textos mediante un modelo de lenguaje, parámetros del negocio, reglas de recomendación y al menos un componente de aprendizaje automático entrenado con datos reales, sujeto a la suficiencia y calidad de los registros disponibles. FhalconFood constituirá el caso piloto principal. La participación de dos organizaciones adicionales se gestionará durante el proyecto y no se considera confirmada. La evaluación contrastará una línea base manual y una alternativa basada en reglas con el componente de aprendizaje automático, usando indicadores operativos y técnicos pertinentes. El proyecto culminará en febrero o marzo del 2027.

1. Antecedentes y actualización de la propuesta

La propuesta inicial fue aprobada con observaciones por el Comité de Titulación. El reporte reconoce la pertinencia del problema y solicita acotar el MVP, incorporar aprendizaje automático real, operacionalizar objetivos, documentar la procedencia y calidad de datos y evaluar el desempeño frente a una línea base. Esta versión sustituye la propuesta anterior a efectos de la actividad S1 y conserva su enfoque multisectorial sin presentar capacidades futuras como implementaciones ya realizadas.

2. Definición del problema

Las micro, pequeñas y medianas empresas pueden requerir tiempo y conocimientos especializados para elaborar mensajes digitales diferenciados por producto, audiencia, objetivo y canal. La preparación manual de variantes y el análisis fragmentado de resultados dificultan comparar opciones y aprovechar datos históricos. En el caso principal de distribución de alimentos al segmento HORECA, se investigará adicionalmente el proceso de atención y clasificación de consultas provenientes de campañas. No se afirma que estas dificultades hayan sido cuantificadas en FhalconFood: su magnitud se establecerá con mediciones iniciales y entrevistas.

2.1 Pregunta de investigación

¿En qué medida un MVP configurable que combina IA generativa y aprendizaje automático, comparado con procesos manuales y recomendaciones basadas en reglas, mejora la eficiencia de preparación y la pertinencia de campañas digitales en el caso piloto principal y permite adaptarse a otros sectores?

2.2 Delimitación y alcance

- Ámbito: apoyo a la creación, segmentación orientativa y recomendación de campañas digitales; no incluye compra automatizada de publicidad ni cierre autónomo de ventas.
- Caso principal confirmado: FhalconFood, con acceso a datos reportado por nuestro equipo; los tipos, volúmenes y permisos de uso específico serán inventariados.
- Casos de contraste: dos sectores adicionales por identificar y vincular; su participación dependerá de acuerdos y disponibilidad de datos.
- MVP prioritario: ficha de negocio, generación de variantes de texto, segmentos o públicos sugeridos, motor de recomendaciones, registro de resultados y demostración acotada de clasificación de consultas si existen datos aptos.
- Fuera de alcance obligatorio: publicación automática multired, pagos, integración simultánea con todas las APIs, generación audiovisual avanzada y operación autónoma de ventas.
- Horizonte: octubre de 2026 a marzo de 2027; el cronograma es preliminar y deberá alinearse con fechas institucionales si se reciben.

2.3 Factibilidad del caso

Dimensión	Criterio y evidencia actual	Acción para comprobar
Técnica	Python, bibliotecas de ML y una interfaz web ligera son opciones técnicamente viables; aún no hay arquitectura validada.	Prototipo incremental y pruebas funcionales.
Datos	Acceso a datos de FhalconFood, pero no su estructura ni cantidad.	Inventario, permisos, diccionario de datos y auditoría de calidad.
Operativa	Dos integrantes y un piloto principal permiten priorizar funciones.	Entrevistas, definición de responsables y validación con usuarios.
Temporal	Plazo hasta el 31/03/2027.	Hitos mensuales y control quincenal del avance.
Ética y legal	Pueden existir datos de clientes y restricciones de uso.	Minimización, anonimización, autorización y revisión humana.
Económica	Posibilidad de herramientas gratuitas o de bajo costo; costos de API aún desconocidos.	Presupuesto de consumo y prueba con límites de gasto.

Conclusión preliminar de factibilidad: el proyecto es plausible como MVP acotado, condicionado a la calidad de los datos, permisos efectivos de uso y cumplimiento de los hitos. No se atribuye factibilidad demostrada a las dos organizaciones todavía no vinculadas.

3. Justificación

El valor aplicado radica en centralizar información de campaña y apoyar la generación de contenido contextualizado y la elección de alternativas, sin sustituir el juicio comercial. El valor académico reside en diseñar una arquitectura configurable, establecer trazabilidad de entradas y recomendaciones, entrenar y evaluar un modelo de aprendizaje automático con datos reales, y contrastarlo con reglas explícitas. Los posibles beneficios —ahorro de tiempo, mayor pertinencia o mejor clasificación— son hipótesis evaluables, no resultados anticipados.

4. Objetivos

4.1 Objetivo general

Desarrollar y evaluar, hasta marzo de 2027, un MVP web multisectorial para apoyar la generación, segmentación y recomendación de campañas digitales mediante IA generativa y al menos un modelo de aprendizaje automático, contrastando su funcionamiento con líneas base manuales y basadas en reglas en FhalconFood y explorando su adaptación a otros dos sectores, sujetos a disponibilidad de participantes y datos.

4.2 Objetivos específicos e indicadores

Objetivo específico	Indicador verificable / evidencia
1. Caracterizar necesidades, procesos y fuentes de datos del piloto principal y gestionar dos casos adicionales.	Al menos una ficha de diagnóstico de FhalconFood; inventario y diccionario de datos; registro de gestiones y acuerdos para dos sectores.
2. Definir requisitos, arquitectura y políticas de manejo de datos del MVP.	Documento de requisitos priorizados, diagrama de arquitectura, esquema de datos y protocolo de tratamiento.
3. Implementar las funciones críticas de generación, recomendaciones y registro de métricas.	MVP ejecutable con pruebas documentadas de flujos prioritarios.
4. Seleccionar, entrenar y comparar un modelo de ML con una línea base de reglas, de acuerdo con los datos auditados.	Informe de selección justificada, particiones, métricas pertinentes, comparación reproducible y análisis de errores.
5. Evaluar utilidad, calidad y riesgos del MVP con usuarios y datos reales disponibles.	Medición de tiempo de preparación, rúbrica de pertinencia, resultados de pruebas y matriz de calidad/riesgo.

Los valores objetivo de mejora y umbrales de aceptación se fijarán tras levantar la línea base y examinar la distribución de datos, evitando porcentajes arbitrarios. La existencia de los documentos y pruebas indicados sí constituye un criterio verificable de avance.

5. Alternativas de solución y selección preliminar

Aspecto	A: LLM + reglas (línea base)	B: LLM + ML (solución a evaluar)
Generación	LLM con revisión humana	LLM con revisión humana
Selección	Ranking por criterios explícitos	Modelo entrenado según tarea y datos
Ventaja	Interpretabilidad y baja exigencia de datos	Posibilidad de aprender patrones empíricos
Limitación	No aprende del histórico	Depende de cantidad, calidad y representatividad
Papel en proyecto	Comparador indispensable	Componente de IA a implementar y validar

Se adopta una estrategia incremental: implementar primero A para contar con un comparador estable y después B si el inventario confirma registros utilizables. No se elige de antemano regresión logística, agrupamiento o un modelo de recomendación: la tarea predictiva, las etiquetas, el tamaño de muestra y la distribución de clases determinarán la elección. Si no existen etiquetas fiables, se evaluará agrupamiento con criterios apropiados; si existen, se priorizará un modelo supervisado sencillo e interpretable. No se afirmará aprendizaje efectivo sin entrenamiento y validación documentados.

La matriz de la propuesta inicial favorecía la alternativa A con puntuaciones 4,34 y 4,16, pero esas puntuaciones son valoraciones preliminares y no evidencia experimental. En esta revisión se mantiene A como línea base, mientras que B será objeto de evaluación empírica; no se reutilizan aquellas puntuaciones como resultados validados.

6. Plan metodológico

Enfoque: investigación aplicada con desarrollo tecnológico y evaluación comparativa; combinación de evidencia cualitativa (entrevistas, evaluación experta y usabilidad) y cuantitativa (tiempos, calidad de clasificación/recomendación y métricas de campañas cuando existan). Diseño: estudio de caso principal con contrastes multisectoriales exploratorios. No se atribuirá causalidad comercial a diferencias observacionales sin controles adecuados.

6.1 Fases, técnicas y productos

Fase	Actividades y técnicas	Producto
I. Diagnóstico	Entrevistas; mapeo de proceso; medición inicial de tiempo; inventario y auditoría de datos.	Requisitos, línea base, inventario y permisos.
II. Diseño	Arquitectura, esquema de datos, flujos, prompts, rúbricas, reglas y protocolos.	Diseño y plan de pruebas.
III. Construcción	Interfaz web; generación con LLM; motor de reglas; trazabilidad y revisión humana.	MVP base y pruebas funcionales.

IV. Aprendizaje automático	Análisis exploratorio, limpieza, partición, selección según datos, entrenamiento y comparación.	Modelo y reporte experimental.
V. Validación	Pruebas con usuarios, evaluación de calidad/riesgo, análisis de errores y contraste entre sectores disponibles.	Resultados, limitaciones y versión final.

6.2 Procedimiento de datos y selección de modelo

- Registrar fuente, fecha, propietario, finalidad y permiso de cada conjunto de datos. Excluir datos personales innecesarios y atributos sensibles de segmentación.
- Describir unidades de análisis: campaña, variante, consulta o lead según registros existentes; identificar duplicados, faltantes, sesgos y desbalance.
- Determinar la tarea a partir de los datos: clasificación de intención si hay consultas etiquetables; recomendación por desempeño si hay suficientes campañas comparables; agrupamiento exploratorio cuando no haya etiquetas.
- Separar entrenamiento y evaluación evitando fuga de información entre campañas o clientes; usar separación temporal cuando corresponda.
- Comparar contra reglas explícitas y, cuando sea posible, contra la decisión manual; reportar intervalos o variabilidad y errores.
- No usar registros sintéticos como sustitutos de evidencia real en las conclusiones de desempeño; pueden emplearse únicamente en pruebas de interfaz y desarrollo, claramente identificados.

6.3 Indicadores y evaluación

Dimensión	Indicador / método	Precaución
Eficiencia	Minutos para preparar una campaña equivalente con proceso manual y MVP.	Mismas condiciones y complejidad comparable.
Pertinencia	Rúbrica de evaluadores sobre adecuación a producto, audiencia, canal y claridad.	Criterios definidos antes de evaluar.
ML supervisado (si aplica)	Precisión, recall, F1 y matriz de confusión; calibración si se predicen probabilidades.	Revisar desbalance y tamaño de muestra.
Agrupamiento (si aplica)	Coherencia interpretativa y medidas internas adecuadas, con revisión experta.	No confundir agrupaciones con etiquetas verdaderas.
Campañas	CTR, interacción o conversiones cuando existan datos reales comparables.	No prometer atribución causal ni mejoras porcentuales.

Calidad y riesgo	Robustez, transparencia, equidad, control humano y trazabilidad, tomando como referencia ISO/IEC 25059 y NIST AI RMF.	Definir pruebas concretas y documentar límites.

6.4 Controles de calidad, ética y riesgos

Todo contenido generado requerirá revisión humana previa a su uso comercial. El sistema registrará versión del prompt, configuración relevante, fuente de datos y decisión de aprobación. Se evitará responder automáticamente sobre precios, stock o crédito sin información vigente validada. Los datos personales se anonimizarán o seudonimizarán cuando corresponda; se restringirá el acceso y se documentará su conservación. Se evaluarán alucinaciones, recomendaciones inapropiadas, sesgos entre sectores y errores de clasificación. Los marcos ISO/IEC 25059:2023, ISO/IEC TS 25058:2024 y NIST AI RMF 1.0 orientarán el diseño de pruebas; no se afirma certificación.

7. Cronograma tentativo y entregables

El calendario siguiente es una planificación propuesta. El cierre se fija al 31 de marzo de 2027.

Periodo	Actividad principal	Hito / entregable
25–31 oct. 2026	Ajuste S1, delimitación y protocolo de acceso a datos.	E1: propuesta y plan metodológico.
Noviembre 2026	Diagnóstico FhalconFood, inventario de datos, línea base y búsqueda de otros sectores.	E2: diagnóstico, requisitos y diccionario de datos.
Diciembre 2026	Arquitectura, prototipo de generación y recomendación por reglas; pruebas funcionales.	E3: MVP A y arquitectura documentada.
Enero 2027	Auditoría de etiquetas; selección condicionada a datos, entrenamiento y comparación preliminar.	E4: modelo ML y comparación preliminar A/B.
Febrero 2027	Integración del modelo, pruebas con usuarios, análisis de métricas y calidad de IA.	E5: MVP integrado e informe de validación.
Marzo 2027	Validación final, correcciones, análisis de limitaciones y redacción del informe final.	E6: memoria, repositorio y demostración (31 mar.).

Actividad / fase	Oct.	Nov.	Dic.	Ene.	Feb.	Mar.
S1, alcance y protocolo	■	.	.	.	.	.
Diagnóstico, datos y sectores	.	■	■	.	.	.
Diseño y arquitectura	.	■	■	.	.	.
MVP: LLM y reglas	.	.	■	■	.	.
Modelo ML: selección y entrenamiento	.	.	.	■	■	.
Integración y evaluación comparativa	.	.	.	■	■	■
Validación y ajustes	.	.	.	.	■	■
Informe, documentación y defensa	.	.	.	.	.	■

7.1 Responsabilidades y seguimiento

El equipo está conformado por dos integrantes. La asignación nominal de tareas se acordará internamente; no se atribuyen responsabilidades individuales sin confirmación. Se propone seguimiento quincenal con registro de avances, bloqueos, evidencias y decisiones. La incorporación de empresas adicionales tendrá un punto de decisión al finalizar noviembre: si no se obtienen acuerdos, se documentará la limitación y se priorizará la validación profunda del caso principal, sin inventar resultados multisectoriales.

8. Riesgos y contingencias

Riesgo	Mitigación / decisión
Datos insuficientes o sin etiquetas	Auditar tempranamente; elegir tarea viable; etiquetado supervisado autorizado; reportar límites.
No vincular dos empresas	Gestionar contactos en noviembre; mantener núcleo configurable; declarar validación sectorial parcial.
Dependencia de API o costos	Abstracción de proveedor, límites de uso y pruebas con alternativas accesibles.
Errores de contenido o privacidad	Revisión humana, restricciones de datos y pruebas de seguridad/pertinencia.
Plazo reducido	Priorizar MVP mínimo y diferir integraciones no esenciales.

9. Aportes y resultados esperados

Se espera obtener una arquitectura de configuración multisectorial, un MVP demostrable, una línea base de reglas, un modelo de aprendizaje automático

efectivamente entrenado cuando la evidencia lo permita, un protocolo reproducible de evaluación y resultados empíricos documentados del piloto. No se presuponen ahorros, tasas de conversión ni generalización a sectores sin datos. La contribución propia del equipo estará en la integración, trazabilidad, definición del problema, preparación de datos, comparación de métodos y análisis de resultados.

10. Referencias bibliográficas

El sustento conceptual de IA generativa en marketing se basa en Huang y Rust (2021), Kshetri et al. (2024) y Grewal et al. (2025); la discusión de riesgos y adopción en Dwivedi et al. (2023) y Chui et al. (2023). Para evaluación de calidad y riesgo se consideran ISO (2023, 2024) y NIST (2023). Las referencias se conservan de la propuesta aprobada; sus metadatos deberán cotejarse con las fuentes originales antes de la entrega definitiva.

Dwivedi, Y. K., et al. (2023). "So what if ChatGPT wrote it?" Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy. International Journal of Information Management, 71, 102642. https://doi.org/10.1016/j.ijinfomgt.2023.102642

Grewal, D., Satornino, C. B., Davenport, T., & Guha, A. (2025). How generative AI is shaping the future of marketing. Journal of the Academy of Marketing Science, 53, 702–722. https://doi.org/10.1007/s11747-024-01064-3 Huang, M.-H., & Rust, R. T. (2021).

A strategic framework for artificial intelligence in marketing. Journal of the Academy of Marketing Science, 49, 30–50. https://doi.org/10.1007/s11747-020-00749-9 Kshetri, N., Dwivedi, Y. K., Davenport, T. H., & Panteli, N. (2024). Generative artificial intelligence in marketing: Applications, opportunities, challenges, and research agenda. International Journal of Information Management, 75, 102716. https://doi.org/10.1016/j.ijinfomgt.2023.102716 International Organization for Standardization. (2023). ISO/IEC 25059:2023: Quality model for AI systems. ISO.

International Organization for Standardization. (2024). ISO/IEC TS 25058:2024: Guidance for quality evaluation of artificial intelligence (AI) systems. ISO.

National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). https://doi.org/10.6028/NIST.AI.100-1 Chui, M., et al. (2023). The economic potential of generative AI: The next productivity frontier. McKinsey Global Institute.

Anexo A. Trazabilidad de observaciones del Comité

Observación	Cambio incorporado
Delimitar funcionalidades	MVP mínimo y exclusiones explícitas, §2.2.
Asegurar componente ML	Selección condicionada a datos, entrenamiento y comparación con reglas, §5–6.
Formalizar datos	Inventario, permisos, calidad y etiquetado, §6.2.
Objetivos medibles	Indicadores y evidencias por objetivo, §4.2.
Calidad y riesgo	Métricas y controles de revisión humana, §6.3–6.4.
Sectores aún no confirmados	Gestión y contingencia explícita, §7.1–8.

Cronograma	Hitos mensuales hasta marzo 2027, §7.

Anexo B. Verificación frente a rúbrica S1

Criterio (20 puntos cada uno)	Ubicación y evidencia
Problema y alcance	§2–2.3: pregunta, delimitación y factibilidad concreta.
Objetivos	§4: objetivo general y objetivos específicos con indicadores.
Plan metodológico	§5–6: alternativas, fases, datos, IA, métricas y riesgos.
Cronograma y entregables	§7: periodos, hitos, entregables y contingencias.
Coherencia y presentación	Portada, resumen, numeración, referencias y anexos.

Anexo C. Información pendiente de verificación

- Inventario real de datos disponibles en FhalconFood: cantidad, campos, periodo, permisos de uso y calidad.
- Identificación, autorización y disponibilidad de dos organizaciones adicionales.
- Umbrales de desempeño y metas de mejora, que se definirán tras medir la línea base.
- Asignación de tareas entre los dos integrantes y eventuales fechas oficiales de la UDLA.
- Verificación bibliográfica final de autores, títulos y datos editoriales contra fuentes originales.