UNIVERSIDAD DE LAS AMÉRICAS

SEMANA 3 – TAREA- ESTADO DEL ARTE Y METODOLOGÍA

PROYECTO DE TITULACIÓN

PROYECTO MIA

TTMZ0055-462
GRUPO 5

Integrantes:

Peter Cañizares

Henry Mantilla

08/11/2026

Índice

1.Contexto y problema 3
2.Estrategia de búsqueda bibliográfica 4
3.Matriz de literatura 5
4.Síntesis crítica del estado del arte 8
5.Propuesta metodológica preliminar 10
6.Referencias bibliográficas 12

1. Contexto y problema

El proyecto de titulación propone una plataforma multisectorial para generar, segmentar y recomendar campañas de marketing digital mediante IA generativa y aprendizaje automático. El caso piloto principal es FhalconFood, distribuidora de alimentos para el segmento HORECA (hoteles, restaurantes, catering y panaderías) en Quito, Ecuador. Las empresas pequeñas y medianas suelen preparar sus campañas de forma manual, con mensajes poco diferenciados por producto, audiencia, canal y con un análisis fragmentado de resultados. En FhalconFood se investigará además la atención y clasificación de las consultas que llegan desde las campañas, sin buscar ventas autonomas: cuando el cliente muestra intención de compra, la conversación pasa a un vendedor humano.

El chatbot como módulo del proyecto: El módulo de atención de consultas se desarrolla como un prototipo de chatbot en Google Colab, adaptado a FhalconFood: clasifica la intención del mensaje en español con un modelo BETO afinado (consulta de catálogo, precio, disponibilidad, intención de compra), responde solo con información del catálogo y las condiciones comerciales vigentes, luego deriva la conversación a un asesor humano, registrando el lead, cuando detecta intención de compra o no puede responder con seguridad. El prototipo usa por ahora datos base y su modelo aún no ha sido entrenado ni evaluado con mensajes reales. El código se mantiene en un repositorio propio.

Este documento presenta el avance del estado del arte y una propuesta metodológica inicial. Partimos de la revisión de la organización en cinco ejes: IA generativa en marketing, IA, chatbots en ventas B2B, segmentación algorítmica de clientes, comprensión de lenguaje en español con respuestas controladas y equidad y riesgo.

2. Estrategia de búsqueda bibliográfica

Se diseñaron seis cadenas de búsqueda con operadores booleanos, comillas para frases exactas y filtros.

N.º	Cadena de búsqueda (sintaxis Scopus)	Eje
S1	TITLE-ABS-KEY (("generative AI" OR "generative artificial intelligence" OR "large language model") *AND marketing AND (campaign* OR content OR personali?ation))	IA generativa en marketing
S2	TITLE-ABS-KEY ((chatbot *OR "conversational agent*") AND ("lead generation" OR "lead qualification" OR sales) AND (B2B OR "business-to-business"))	Chatbots y ventas B2B
S3	TITLE-ABS-KEY (("customer segmentation" OR "market segmentation") AND ("machine learning" OR clustering OR "k-means") AND (review OR "systematic review"))	Segmentación
S4	TITLE-ABS-KEY ((fairness OR bias) AND ("marketing algorithm*" OR "targeted advertising" OR "personali?ed advertising"))	Equidad y sesgo
S5	TITLE-ABS-KEY ((BETO OR "Spanish BERT") AND ("intent classification" OR "intent recognition" OR chatbot))	PLN en español
S6	TITLE-ABS-KEY (("retrieval-augmented generation" OR RAG) AND hallucination AND ("question answering" OR "customer service"))	Respuestas controladas

Filtros: Años 2021–2025, artículos de revista, revisiones sistemáticas, editoriales de números especiales y preprints en temas de modelos de lenguaje; idiomas como inglés y español.

Criterios de inclusión: Relación directa con alguno de los cinco ejes, aporte conceptual o empírico verificable en el resumen, datos editoriales completos.

Exclusión: blogs, páginas comerciales y reportes de proveedores de software, aun cuando aparecieron entre los resultados. Se seleccionaron 14 fuentes cuya matriz se presenta a continuación.

3. Matriz de literatura

Matriz de literatura: 14 fuentes verificadas en la página editorial, en el repositorio o en el texto completo del artículo (2020–2026).

Cita (APA 7)	Objetivo del estudio	Método o técnica de IA aplicada	Hallazgos relevantes	Vacíos o limitaciones	Relación con nuestro problema
Grewal, D., Satornino, C. B., Davenport, T., & Guha, A. (2025). How generative AI is shaping the future of marketing. *Journal of the Academy of Marketing Science, 53*(3), 702–722. https://doi.org/10.1007/s11747-024-01064-3	Analizar cómo la IA generativa puede transformar el marketing en la próxima década (interacción con clientes, contenido e I+D).	Artículo conceptual; marco de cuatro cuadrantes (naturaleza del insumo × grado de aumento humano).	La IA generativa afectará la comunicación y la creación de contenido, con impacto directo en servicio y ventas; el marco orienta qué casos de uso elegir y cuánta supervisión humana requieren.	Sin validación empírica ni métricas de desempeño.	Sustenta la revisión humana obligatoria y la selección de casos de uso: generación de variantes y atención de consultas.
Kshetri, N., Dwivedi, Y. K., Davenport, T. H., & Panteli, N. (2024). Generative artificial intelligence in marketing: Applications, opportunities, challenges, and research agenda. *International Journal of Information Management, 75*, Artículo 102716. https://doi.org/10.1016/j.ijinfomgt.2023.102716	Delinear el estado de la IA generativa en marketing: aplicaciones, oportunidades y desafíos.	Artículo editorial; sin recolección empírica.	Factores que facilitan o frenan la adopción; contenido más personalizado y mayor eficiencia; papel en la generación de leads de ventas.	Sus afirmaciones de efectividad no se apoyan en datos propios; deja agenda de investigación abierta.	Respalda la hipótesis de ahorro de tiempo y pertinencia, que se debe medir en el piloto y no asumir.
Huang, M.-H., & Rust, R. T. (2021). A strategic framework for artificial intelligence in marketing. *Journal of the Academy of Marketing Science, 49*, 30–50. https://doi.org/10.1007/s11747-020-00749-9	Proponer un marco para planificar la IA en investigación de mercado, estrategia (segmentación, selección de público, posicionamiento) y acción.	Marco conceptual con tres tipos de IA: mecánica, de pensamiento y de sentimiento.	Cada tipo de IA se asocia a una etapa del marketing; la colaboración humano-IA seguirá siendo importante en el corto plazo.	La IA de pensamiento puede ser opaca y sesgada; el marco no está probado empíricamente.	Ubica segmentación, recomendación y personalización en un marco; justifica explicabilidad y una línea base de reglas.
Isabella, G., Almeida, M. I. S. de, Duran, F. M., & Gabler, C. (2025). From static to conversational: The role of landing pages and chatbots in B2B lead generation. *Journal of Business Research, 201*, Artículo 115681. https://doi.org/10.1016/j.jbusres.2025.115681	Comparar chatbots en WhatsApp con páginas de aterrizaje para generar leads B2B (cantidad y calidad).	Dos experimentos de campo (Meta y Google Ads) y 17 entrevistas a gerentes y clientes B2B.	Los chatbots generaron más leads y de mayor calidad; los impulsores fueron respuesta rápida, seguridad percibida y personalización; el efecto depende de la complejidad de compra y del deseo de control del comprador.	Datos de una sola pyme B2B brasileña y una agencia socia; un coautor trabaja en esa agencia (declarado).	Es la evidencia más cercana a nuestro caso (campañas que llevan a WhatsApp en B2B); apoya probar el chat con paso a vendedor humano.
Dwivedi, Y. K., & Wang, Y. (2022). Guest editorial: Artificial intelligence for B2B marketing: Challenges and opportunities. *Industrial Marketing Management, 105*, 109–113. https://doi.org/10.1016/j.indmarman.2022.06.001	Presentar un número especial sobre IA en marketing B2B y delimitar sus retos y oportunidades.	Editorial que reúne 16 artículos cualitativos y cuantitativos.	Hay poca investigación de IA en mercados industriales frente al consumidor final; los trabajos se agrupan en cuatro temas (adopción, innovación y cadena de suministro, experiencia con el cliente, capacidades dinámicas).	Es un editorial; no reporta resultados propios.	Justifica el vacío que aborda el proyecto: IA aplicada a distribución B2B (HORECA).

Cita (APA 7)	Objetivo del estudio	Método o técnica de IA aplicada	Hallazgos relevantes	Vacíos o limitaciones	Relación con nuestro problema
Fehrenbach, D., Herrando, C., & Martín-De Hoyos, M. J. (2024). Co-creation with AI in B2B markets: A systematic literature review. *Sustainability, 16*(18), Artículo 8009. https://doi.org/10.3390/su16188009	Mapear el estado del arte de la cocreación con IA en mercados B2B.	Revisión sistemática (PRISMA) en Scopus y Web of Science; 10 publicaciones.	La participación humana sigue siendo central; la IA puede apoyar todas las etapas del embudo de ventas; se requieren capacidades técnicas e interpersonales.	Pocos estudios, casi todos cualitativos o conceptuales; riesgos de privacidad y dependencia de grandes proveedores; poca atención a la pérdida de valor por mala cooperación humano-IA.	Refuerza derivar al vendedor humano y los controles de privacidad en el manejo de datos.
Salminen, J., Mustak, M., Sufyan, M., & Jansen, B. J. (2023). How can algorithms help in segmenting users and customers? A systematic review and research agenda for algorithmic customer segmentation. *Journal of Marketing Analytics, 11*(4), 677–692. https://doi.org/10.1057/s41270-023-00235-5	Revisar cómo se segmenta a clientes con algoritmos y proponer una agenda de investigación.	Revisión sistemática (Kitchenham); 172 artículos, 134 basados en algoritmos.	K-means es el algoritmo más usado; se suelen crear unos cuatro segmentos; solo 4,1 % de los estudios involucra a expertos para evaluar los segmentos.	Faltan criterios estándar de evaluación y evidencia de resultados de negocio.	Guía el módulo de segmentación: probar K-means con medidas internas y validar los segmentos con el equipo comercial.
Yang, M., Guo, J., Zhu, L., Zhu, H., Song, X., Zhang, H., & Xu, T. (2024). Fairness evaluation of marketing algorithms: A framework for equity distribution. *Journal of Electronic Business & Digital Economics, 3*(3), 251–274. https://doi.org/10.1108/JEBDE-10-2023-0024	Construir un sistema de índices para evaluar la equidad de algoritmos de marketing.	Revisión de criterios de equidad y evaluación con datos de marketing simulados.	Distintos criterios de equidad dan resultados distintos; la equidad puede evaluarse en cobertura, intensidad y frecuencia.	Un solo conjunto de datos simulado; no explora intervenciones para mejorar la equidad.	Base para las métricas de equidad al segmentar y recomendar campañas.
Fernández-Martínez, F., Luna-Jiménez, C., Kleinlein, R., Griol, D., Callejas, Z., & Montero, J. M. (2022). Fine-tuning BERT models for intent recognition using a frequency cut-off strategy for domain-specific vocabulary extension. *Applied Sciences, 12*(3), Artículo 1610. https://doi.org/10.3390/app12031610	Comparar redes recurrentes y transformers para detectar intenciones en un asistente de preguntas frecuentes en español.	BiLSTM con atención frente a BERT y BETO; validación cruzada de 5 pliegues; extensión de vocabulario por frecuencia.	Los transformers superaron a la red recurrente; BETO cased fue el mejor; añadir 50 tokens subió la exactitud de 78,2 % a 79,5 %; el preprocesamiento agresivo empeoró los resultados.	Un solo dominio (COVID-19) y datos restringidos; sin búsqueda exhaustiva de hiperparámetros.	Respalda BETO como candidato para clasificar consultas en español; sugiere comparar variantes cased y uncased y no sobreprocesar el texto.
Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2023). *Spanish pre-trained BERT model and evaluation data* [Preprint]. arXiv. https://arxiv.org/abs/2308.02976	Cubrir la escasez de recursos para entrenar y evaluar modelos de lenguaje en español.	Preentrenamiento de BERT solo con datos en español y compilación de tareas tipo GLUE.	Tras el ajuste fino supera a BERT multilingüe en la mayoría de tareas y fija nuevo estado del arte en algunas.	Evaluado en tareas de dominio general, no en lenguaje comercial; es preprint.	Origen del modelo BETO; su uso en consultas comerciales exige ajuste con datos propios.
Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-augmented generation for large language models: A survey* (arXiv:2312.10997v4) [Preprint]. arXiv. https://arxiv.org/abs/2312.10997	Revisar la generación aumentada por recuperación (RAG) para reducir alucinaciones y conocimiento desactualizado en modelos de lenguaje.	Revisión de literatura; paradigmas Naive, Advanced y Modular; marco de evaluación.	RAG mejora la exactitud y credibilidad en tareas intensivas en conocimiento y permite actualizar información sin reentrenar.	Deja retos abiertos y direcciones futuras; es preprint.	Respalda que precios y disponibilidad salgan de un catálogo validado y no del modelo de lenguaje.

Cita (APA 7)	Objetivo del estudio	Método o técnica de IA aplicada	Hallazgos relevantes	Vacíos o limitaciones	Relación con nuestro problema
Rakin, S., Shibly, M. A. R., Hossain, Z. M., Khan, Z., & Akbar, M. M. (2024). *Leveraging the domain adaptation of retrieval augmented generation models for question answering and reducing hallucination* (arXiv:2410.17783) [Preprint]. arXiv. https://arxiv.org/abs/2410.17783	Evaluar la adaptación de dominio de modelos RAG para preguntas y respuestas y reducir alucinaciones.	Nuevo conjunto HotelConvQA (conversaciones de hotel); ajuste fino y evaluación de varias arquitecturas RAG.	La adaptación de dominio mejoró todas las métricas y redujo de forma significativa la alucinación en todas las arquitecturas.	Un solo dominio (hotelería); es preprint.	Caso cercano al HORECA; sugiere adaptar el sistema al dominio y medir la tasa de alucinación.
Abbas, F. A., Carlson, J., Rahman, S. M., & Gudergan, S. P. (2026). Chatbot service quality in omnichannel retailing: Effects of ChatbotSQ on decision confidence and customer behavior. *Journal of Retailing and Consumer Services, 95*, Artículo 105151. https://doi.org/10.1016/j.jretconser.2026.105151	Examinar cómo la calidad de servicio del chatbot (ChatbotSQ) influye en la confianza para decidir, el tiempo que el cliente dedica al chatbot y su permanencia en el ecosistema omnicanal.	Encuestas a clientes de Estados Unidos y Arabia Saudita; modelo de ecuaciones estructurales por mínimos cuadrados parciales (PLS-SEM) y análisis de condición necesaria (NCA).	Mayor ChatbotSQ se asocia con más confianza para decidir, más tiempo con el chatbot y mayor permanencia; hay niveles mínimos necesarios de calidad y de confianza; se recomienda diseñar el chatbot para que el cliente llegue a decidir, con confirmaciones y vías de escalamiento.	Diseño transversal y conductas autorreportadas; comercio minorista B2C en solo dos países; el efecto moderador de la comodidad con el chatbot no se replica en ambas muestras.	Aporta dimensiones de calidad del chat (funcionalidad, integración, interfaz, personalización) y la confianza para decidir como métrica; apoya incluir vías de escalamiento al vendedor humano.
Abd-El-Salam, E. M., & Youssef, A. H. (2026). Investigating the impact of chatbot interactivity on consumer behavior. *Humanities and Social Sciences Communications, 13*, Artículo 996. https://doi.org/10.1057/s41599-026-08081-3	Probar un modelo que integra TAM y SOR para explicar cómo la capacidad de respuesta, la personalización, la calidad de la información y el control del chatbot influyen en la utilidad y facilidad de uso percibidas, la actitud y la confianza, y de ahí en la dependencia, la intención de compra y la resistencia.	Encuesta transversal a 366 consumidores egipcios con experiencia previa en chatbots; modelado de ecuaciones estructurales (SmartPLS3).	Los cuatro estímulos influyen de forma positiva en la utilidad y la facilidad de uso percibidas; la calidad de la información fue el efecto más fuerte; la utilidad impulsa la confianza y la actitud impulsa la intención de compra; la confianza influye en la dependencia, la intención de compra y la resistencia.	Muestra por conveniencia, un solo país emergente y datos autorreportados; no incluye variables como experiencia o riesgo percibido.	Respalda cuidar la calidad de la información y la personalización del chat, y medir la confianza del cliente como mediador de su uso.

4. Síntesis crítica del estado del arte

Principales tendencias encontradas

La IA generativa se entiende como complemento del trabajo humano: Grewal et al. (2025), Kshetri et al. (2024) y Huang y Rust (2021) coinciden en que su valor en marketing depende de elegir bien los casos de uso y de definir cuánta supervisión humana requiere cada salida. Destacan la personalización y la eficiencia en la creación de contenido, incluso para generar leads (Kshetri et al., 2024). Sin embargo, estas tres fuentes son conceptuales, la promesa de ahorro de tiempo o de mayor pertinencia sigue sin verificarse con datos, por lo que en nuestro proyecto se tratará como hipótesis y no como resultado.

El marketing B2B es el contexto menos estudiado: Dwivedi y Wang (2022) señalan que la investigación sobre IA en mercados industriales es escasa frente a la dirigida al consumidor final. La revisión de Fehrenbach et al. (2024) encontró solo diez publicaciones sobre IA en B2B, en su mayoría cualitativas o conceptuales y concluye que la participación humana sigue siendo central, con riesgos de privacidad y de dependencia de pocos proveedores tecnológicos.

El canal conversacional rinde en B2B, con condiciones: Isabella et al. (2025) aportan la evidencia experimental más cercana a nuestro caso los chatbots en WhatsApp generaron más leads y de mayor calidad que las landing page, gracias a la rapidez de respuesta, la seguridad percibida y la personalización. Los propios autores advierten que el efecto depende de la complejidad de la compra y del deseo de control del comprador, y su evidencia proviene de una sola Pyme brasileña. En la distribución de alimentos a hoteles y restaurantes, con ciclos de venta consultivos y clientes que negocian condiciones, esa advertencia es relevante debido a que el chatbot resolvería lo repetitivo y el vendedor humano atendería la negociación. Abd-El-Salam y Youssef (2026) coinciden con 366 consumidores egipcios, la calidad de la información y la personalización fueron los estímulos que más elevaron la utilidad percibida y la confianza, que a su vez predijo la dependencia del chatbot.

La segmentación algorítmica es madura, pero poco validada por expertos: Salminen et al. (2023) revisaron 172 estudios, K-means es el algoritmo más usado, se suelen crear unos cuatro segmentos y solo 4,1 % de los trabajos involucra a expertos del negocio en la evaluación. Faltan además criterios comunes de evaluación y evidencia de resultados comerciales.

Comprensión del español y respuestas controladas: Para clasificar intenciones en español, BETO (Cañete et al., 2023) es un punto de partida sólido, Fernández-Martínez et al. (2022) lo encontraron mejor que una red recurrente y que otras variantes de BERT en un asistente de preguntas frecuentes y observaron que el preprocesamiento

agresivo empeoraba los resultados. Para evitar que el modelo invente datos, la literatura propone generación aumentada por recuperación (Gao et al., 2024) y adaptación al dominio, que en un caso de hotelería redujo la alucinación en todas las arquitecturas probadas (Rakin et al., 2024).

Equidad y riesgo: Huang y Rust (2021) advierten que la IA de pensamiento puede ser opaca y producir resultados sesgados. Yang et al. (2024) proponen evaluar la equidad de algoritmos de marketing en tres dimensiones y muestran que distintos criterios de equidad pueden dar conclusiones distintas, por lo que deben escogerse según el contexto.

Cómo se ha abordado el problema en investigaciones previas:

No encontramos estudios que integren estos módulos en una plataforma configurable para varios sectores y la evalúen con datos reales de una empresa B2B de alimentos. Además, en las búsquedas realizadas la literatura académica sobre criterios para derivar un chatbot a un vendedor humano fue escasa.

Relación con el problema del proyecto y vacíos que se abordarán:

Los hallazgos se traducen en decisiones concretas y en vacíos que el proyecto busca cubrir como los siguientes:

- **Evidencia mayormente conceptual:** se medirá contra una línea base manual y otra basada en reglas, sin prometer porcentajes de mejora.
- **Poca investigación en B2B, en HORECA:** el caso piloto es FhalconFood y la evaluación de intenciones se hará con mensajes reales.
- **Segmentos poco validados por expertos:** el equipo comercial de FhalconFood revisará los segmentos sugeridos.
- **Riesgo de alucinación:** los precios, el stock y el crédito se responderán solo desde información vigente validada; sin ella, el sistema derivará a una persona real.
- **Equidad poco estudiada en B2B:** se auditará la cobertura, intensidad y frecuencia de las recomendaciones entre tipos de negocio.

En conjunto, el estado del arte respalda una arquitectura que combine IA generativa con control humano, el aprendizaje automático será solo donde los datos lo permitan y la comparación contra una línea base de reglas, lo que coincide con las alternativas A y B del plan metodológico.

5. Propuesta metodológica preliminar

Tipo de inteligencia artificial: El proyecto combina cuatro tipos de IA, cada uno con un rol distinto:

- IA generativa para redactar variantes de campañas y mensajes, siempre con revisión humana y respuestas apoyadas en el catálogo mediante recuperación RAG.
- Aprendizaje automático supervisado, con BETO afinado para clasificar la intención de los mensajes y si hay datos suficientes un modelo para ordenar recomendaciones de campañas.
- Aprendizaje automático no supervisado, como K-means, para proponer segmentos de clientes.
- Reglas explícitas como línea base de comparación y como control de seguridad. Las alternativas del plan son la A, modelo de lenguaje con reglas. Por otro lado la B, modelo de lenguaje con aprendizaje automático. El prototipo de chatbot de Colab usa por ahora BETO, vectores de oraciones (SBERT) y respuestas controladas desde el catálogo, sin generación libre de texto; la parte generativa se incorporará en el MVP y se evaluará frente a esta base.

Enfoque: Investigación aplicada con desarrollo tecnológico y evaluación comparativa: la alternativa A, actúa como línea base y la alternativa B se evalúa solo si los datos son suficientes.

Datos: Como catálogo y precios referenciales de FhalconFood, y métricas agregadas de campañas, aportadas por la empresa, mensajes de clientes etiquetados por intención. El inventario real de datos de campañas anteriores para tener una comparición real, los datos sintéticos servirán solo para desarrollo de la interfaz, claramente identificados y no para concluir sobre desempeño.

Componente	Técnica potencial (con respaldo en la literatura) y métricas preliminares
Generación de contenido	Modelo de lenguaje con revisión humana y recuperación sobre el catálogo (Gao et al., 2024; Grewal et al., 2025). *Métricas:* minutos de preparación frente al proceso manual; rúbrica de pertinencia (producto, audiencia, canal, claridad); tasa de alucinación (respuestas con precio o stock no respaldados por el catálogo).
Clasificación de consultas	BETO afinado (Cañete et al., 2023; Fernández-Martínez et al., 2022), comparado con reglas o un clasificador clásico; la elección final dependerá de los datos. *Métricas:* precisión, recall, F1 por clase, matriz de confusión; partición sin fuga de información; precisión y recall de la derivación a humano; calidad percibida del chat y confianza del cliente para decidir mediante una breve encuesta (Abbas et al., 2026; Abd-El-Salam y Youssef, 2026).
Segmentación y recomendación	Agrupamiento (p. ej. K-means) con medidas internas y revisión experta (Salminen et al., 2023), si no hay etiquetas; ranking por reglas (A) frente a modelo supervisado (B) si hay campañas suficientes. *Métricas:* coherencia de segmentos; CTR, interacción, consultas y conversiones solo con datos reales comparables.
Interpretabilidad y riesgo	Reglas explícitas y trazabilidad de entradas y salidas (prompt, fuente, aprobación). *Métricas:* explicación por recomendación, errores críticos de clasificación, robustez; criterios de ISO/IEC 25059:2023 y NIST AI RMF 1.0.

Prototipo del chatbot: El prototipo de Colab se evaluará con mensajes reales etiquetados por intención, comparando el clasificador BETO afinado con una línea base de reglas por palabras clave. Se medirán precisión, recall y la tasa de alucinación en precios y disponibilidad. Los precios, el stock y las condiciones de crédito se responderán solo desde el catálogo validado por la empresa.

Variables:

- **Independientes:** sector, segmento, canal, tipo de campaña y alternativa (A o B).

- **Dependientes:** intención predicha, derivación a humano, tiempo de preparación, pertinencia y métricas de campaña.

Sesgos y equidad: Se auditarán la cobertura, intensidad y frecuencia de las recomendaciones, las tasas de error de la clasificación según el modo de redacción de los mensajes. Se revisarán desbalance de clases y tamaño de muestra y todo contenido pasará por revisión humana antes de usarse comercialmente.

6. Referencias bibliográficas

Abbas, F. A., Carlson, J., Rahman, S. M., & Gudergan, S. P. (2026). Chatbot service quality in omnichannel retailing: Effects of ChatbotSQ on decision confidence and customer behavior. *Journal of Retailing and Consumer Services, 95*, Artículo 105151. https://doi.org/10.1016/j.jretconser.2026.105151

Abd-El-Salam, E. M., & Youssef, A. H. (2026). Investigating the impact of chatbot interactivity on consumer behavior. *Humanities and Social Sciences Communications, 13*, Artículo 996. https://doi.org/10.1057/s41599-026-08081-3

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2023). *Spanish pre-trained BERT model and evaluation data* [Preprint]. arXiv. https://arxiv.org/abs/2308.02976

Dwivedi, Y. K., & Wang, Y. (2022). Guest editorial: Artificial intelligence for B2B marketing: Challenges and opportunities. *Industrial Marketing Management, 105*, 109–113. https://doi.org/10.1016/j.indmarman.2022.06.001

Fehrenbach, D., Herrando, C., & Martín-De Hoyos, M. J. (2024). Co-creation with AI in B2B markets: A systematic literature review. *Sustainability, 16*(18), Artículo 8009. https://doi.org/10.3390/su16188009

Fernández-Martínez, F., Luna-Jiménez, C., Kleinlein, R., Griol, D., Callejas, Z., & Montero, J. M. (2022). Fine-tuning BERT models for intent recognition using a frequency cut-off strategy for domain-specific vocabulary extension. *Applied Sciences, 12*(3), Artículo 1610. https://doi.org/10.3390/app12031610

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-augmented generation for large language models: A survey* (arXiv:2312.10997v4) [Preprint]. arXiv. https://arxiv.org/abs/2312.10997

Grewal, D., Satornino, C. B., Davenport, T., & Guha, A. (2025). How generative AI is shaping the future of marketing. *Journal of the Academy of Marketing Science, 53*(3), 702–722. https://doi.org/10.1007/s11747-024-01064-3

Huang, M.-H., & Rust, R. T. (2021). A strategic framework for artificial intelligence in marketing. *Journal of the Academy of Marketing Science, 49*, 30–50. https://doi.org/10.1007/s11747-020-00749-9

International Organization for Standardization. (2023). *ISO/IEC 25059:2023 Software engineering—Systems and software Quality Requirements and Evaluation (SQuaRE)—Quality model for AI systems*. ISO.

Isabella, G., Almeida, M. I. S. de, Duran, F. M., & Gabler, C. (2025). From static to conversational: The role of landing pages and chatbots in B2B lead generation. *Journal of Business Research, 201*, Artículo 115681. https://doi.org/10.1016/j.jbusres.2025.115681

Kshetri, N., Dwivedi, Y. K., Davenport, T. H., & Panteli, N. (2024). Generative artificial intelligence in marketing: Applications, opportunities, challenges, and research agenda. *International Journal of Information Management, 75*, Artículo 102716. https://doi.org/10.1016/j.ijinfomgt.2023.102716

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* (NIST AI 100-1). U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.100-1

Rakin, S., Shibly, M. A. R., Hossain, Z. M., Khan, Z., & Akbar, M. M. (2024). *Leveraging the domain adaptation of retrieval augmented generation models for question answering and reducing hallucination* (arXiv:2410.17783) [Preprint]. arXiv. https://arxiv.org/abs/2410.17783

Salminen, J., Mustak, M., Sufyan, M., & Jansen, B. J. (2023). How can algorithms help in segmenting users and customers? A systematic review and research agenda for algorithmic customer segmentation. *Journal of Marketing Analytics, 11*(4), 677–692. https://doi.org/10.1057/s41270-023-00235-5

Yang, M., Guo, J., Zhu, L., Zhu, H., Song, X., Zhang, H., & Xu, T. (2024). Fairness evaluation of marketing algorithms: A framework for equity distribution. *Journal of Electronic Business & Digital Economics, 3*(3), 251–274. https://doi.org/10.1108/JEBDE-10-2023-0024